

Predicción de Demanda E-Commerce

Reporte Técnico: EDA, Modelos de Redes Neuronales, Validación Cruzada, Tuning y Pruebas Estadísticas


Fecha de generación: 2026-07-11 19:04:02

1. Análisis Exploratorio de Datos (EDA)


1.1 Estadísticos Descriptivos

Variable	Media	Mediana	Moda	Varianza	DesviaciónEstándar	Mínimo	Máximo	Percentil25	Percentil50	Percentil75
Quantity	7.272	5.000	1.000	43.539	6.598	1.000	27.000	2.000	5.000	12.000
UnitPrice	2.132	1.650	1.250	2.256	1.502	0.001	7.500	1.250	1.650	2.950
CustomerID	15327.478	15249.000	17841.000	2925012.760	1710.267	12347.000	18287.000	13995.000	15249.000	16827.000
Año	2010.936	2011.000	2011.000	0.060	0.246	2010.000	2011.000	2011.000	2011.000	2011.000
Mes	7.652	9.000	11.000	11.606	3.407	1.000	12.000	5.000	9.000	11.000
Día	15.059	15.000	6.000	75.059	8.664	1.000	31.000	7.000	15.000	22.000
Hora	12.782	13.000	12.000	5.061	2.250	6.000	20.000	11.000	13.000	14.000
DíaSemana	2.640	3.000	3.000	3.805	1.951	0.000	6.000	1.000	3.000	4.000
SemanaAño	31.138	35.000	48.000	216.552	14.716	1.000	51.000	19.000	35.000	44.000
EsFinDeSemana	0.165	0.000	0.000	0.138	0.372	0.000	1.000	0.000	0.000	0.000
Ingresos	11.316	9.960	15.000	77.209	8.787	0.001	42.000	3.750	9.960	16.500
Trimestre	2.870	3.000	4.000	1.254	1.120	1.000	4.000	2.000	3.000	4.000


Interpretación: La variable objetivo (Quantity) presenta una media de 7.27 unidades con una desviación estándar de 6.60, lo que indica alta dispersión respecto a la media (coeficiente de variación elevado). Esto es consistente con datos de ventas al detalle, donde unos pocos pedidos de gran volumen conviven con la mayoría de pedidos pequeños. Esta asimetría explica en parte la dificultad de los modelos para lograr un ajuste alto (ver sección de comparación de modelos).



Mapa de calor de correlaciones entre variables numéricas del dataset. Sirve para identificar redundancia entre variables predictoras y su relación lineal con la variable objetivo.



Serie temporal de ventas agregadas, útil para detectar estacionalidad y tendencia que un modelo secuencial (LSTM/GRU) debería poder capturar.



Distribución de pedidos por país.


2. Entrenamiento y Comparación de Modelos

Se entrenaron tres modelos clásicos (MLP, LSTM, GRU) y dos modelos híbridos (CNN-LSTM, CNN-GRU), guardando el mejor modelo en formato .keras para su consumo directo desde el backend sin necesidad de reentrenamiento.

2.1 Tabla Comparativa (MAE, RMSE, MSE, MAPE, R², Tiempo, Épocas)

Modelo	MAE	RMSE	MSE	MAPE	R ²	Tiempo	Épocas
MLP	5.508	6.707	44.986	208.750	-0.039	93.317	11.000
GRU	12.689	45.020	2026.821	356.978	-0.000	1285.121	33.000
CNN-GRU	12.359	45.023	2027.068	340.600	-0.000	234.570	12.000
LSTM	12.342	45.023	2027.098	339.756	-0.000	359.214	11.000
CNN-LSTM	12.061	45.032	2027.888	323.414	-0.001	206.081	11.000

Interpretación: El modelo con menor error (RMSE = 6.707, MAE = 5.508) fue MLP. Es importante señalar, con honestidad estadística, que el coeficiente de determinación (R²) máximo alcanzado entre los cinco modelos es -0.0000, un valor cercano a cero o negativo en varios casos. Un R² negativo indica que el modelo predice peor que una línea base trivial (la media de la variable objetivo), por lo que ninguno de los modelos entrenados logra capturar de forma confiable la relación entre las variables predictoras y la demanda real. El MAPE (superior al 200% en todos los modelos) confirma esta limitación. Esto no invalida el pipeline técnico -EDA, entrenamiento, validación cruzada, tuning y pruebas estadísticas están correctamente implementados- pero sí exige reportar el hallazgo tal como es: con las variables disponibles (StockCode, UnitPrice, CustomerID, Country y variables temporales) el problema de predicción de demanda a nivel de línea de pedido tiene una señal muy débil. Se recomienda, para el artículo científico, discutir esta limitación y proponer ingeniería de características adicional (por ejemplo, medias móviles de demanda histórica por producto, o agregación a nivel diario/semanal) como trabajo futuro.




Distribución del error (RMSE) de cada modelo a través de los folds de validación cruzada; los boxplots más altos y dispersos indican modelos menos estables.

3. Validación Cruzada (5 folds)

3.1 Resumen por Modelo (media ± desviación estándar)

model	mean_mae	std_mae	min_mae	max_mae	mean_mse	std_mse	min_mse	max_mse	mean_rmse	std_rmse	min_rmse	max_rmse
mlp	11.067	0.899	10.131	12.534	21696.487	40069.546	1352.480	101834.422	96.350	111.414	36.776	311.414
lstm	12.642	0.616	11.707	13.622	21789.276	40079.911	1449.683	101947.961	97.242	111.055	38.075	311.055
gru	12.732	0.493	12.226	13.654	21789.006	40079.951	1448.497	101947.766	97.239	111.056	38.059	311.056
cnn_lstm	12.586	0.654	11.714	13.732	21789.208	40079.743	1449.611	101947.555	97.242	111.055	38.074	311.055
cnn_gru	12.571	0.593	11.714	13.560	21789.314	40079.998	1449.613	101948.172	97.242	111.055	38.074	311.055

Interpretación: Tras 5 particiones (folds) de validación cruzada, el modelo 'mlp' obtuvo el RMSE promedio más bajo (96.350 ± 111.414). La desviación estándar entre folds se reporta junto al promedio para evaluar la estabilidad del modelo: una desviación baja respecto a la media indica que el desempeño no depende fuertemente de la partición particular de los datos, mientras que una desviación alta (como ocurre aquí en varios modelos) sugiere sensibilidad a la muestra y refuerza la necesidad de más datos o de variables predictoras más informativas.



RMSE promedio por modelo en validación cruzada, con barras de error.

4. Ajuste de Hiperparámetros (Tuning)

Interpretación: El ajuste de hiperparámetros (búsqueda aleatoria) seleccionó, para cada arquitectura, la combinación que minimizó la función de pérdida en el conjunto de validación:

MLP: neurons=128, dropout=0.2, learning_rate=0.001


LSTM: lstm_units=32, dropout=0.5, learning_rate=0.001

GRU: gru_units=128, dropout=0.2, learning_rate=0.0001

CNN_LSTM: cnn_filters=32, kernel_size=3, lstm_units=32, dropout=0.3, learning_rate=0.001

CNN_GRU: cnn_filters=64, kernel_size=3, gru_units=64, dropout=0.3, learning_rate=0.001.

Estos valores fueron los usados para reentrenar los modelos finales evaluados en la comparación y en la validación cruzada.



Comparación de resultados obtenidos durante el ajuste de hiperparámetros.

5. Pruebas Estadísticas Robustas


5.1 Ranking de Modelos (Friedman / RMSE)

model	rmse	rank
mlp	96.350	1.000
gru	97.239	2.000
cnn_lstm	97.242	3.000
lstm	97.242	4.000
cnn_gru	97.242	5.000

Interpretación: La prueba de Friedman (estadístico = 10.880, $p = 0.0279$, $\alpha = 0.05$) indica que existen diferencias significativas entre al menos dos de los modelos comparados. El ranking global por RMSE quedó: 1) mlp, 2) gru, 3) cnn_lstm, 4) lstm, 5) cnn_gru. La prueba post-hoc de Nemenyi identificó diferencias estadísticamente significativas en los siguientes pares: cnn_gru vs mlp, lstm vs mlp. En el resto de comparaciones por pares no se pudo rechazar la hipótesis de igualdad de rendimiento. De las 10 comparaciones pareadas evaluadas con la prueba de Wilcoxon (con corrección de Bonferroni), 0 resultaron estadísticamente significativas.

5.2 Comparaciones Pareadas (Wilcoxon, corrección Bonferroni)

model_a	model_b	statistic	p_value	cohens_d	cohens_interpretation	cliffs_delta	cliffs_interpretation	mean_a	mean_b	mean_diff	p_value
cnn_gru	cnn_lstm	7.000	1.000	0.018	Despreciable	0.040	Despreciable	97.242	97.242	0.000	1.000
cnn_gru	gru	3.000	0.312	0.481	Pequeño	0.040	Despreciable	97.242	97.239	0.003	1.000
cnn_gru	lstm	6.000	0.812	0.010	Despreciable	0.040	Despreciable	97.242	97.242	0.000	1.000
cnn_gru	mlp	0.000	0.062	2.107	Grande	0.200	Pequeño	97.242	96.350	0.892	0.625
cnn_lstm	gru	5.000	0.625	0.478	Pequeño	0.040	Despreciable	97.242	97.239	0.003	1.000
cnn_lstm	lstm	6.000	0.812	-0.012	Despreciable	-0.040	Despreciable	97.242	97.242	-0.000	1.000
cnn_lstm	mlp	0.000	0.062	2.104	Grande	0.200	Pequeño	97.242	96.350	0.892	0.625
gru	lstm	4.000	0.438	-0.446	Pequeño	-0.120	Despreciable	97.239	97.242	-0.003	1.000
gru	mlp	0.000	0.062	2.116	Grande	0.200	Pequeño	97.239	96.350	0.889	0.625
lstm	mlp	0.000	0.062	2.105	Grande	0.200	Pequeño	97.242	96.350	0.892	0.625



Mapa de calor de p -valores de las comparaciones pareadas; celdas por debajo de $\alpha = 0.05$ señalan diferencias estadísticamente significativas entre modelos.




Diagrama de diferencia crítica (Nemenyi): modelos conectados por una línea no difieren significativamente en su ranking.

6. Conclusiones

Conclusiones Estadísticas

Fecha: 2026-07-09 16:15:06

1. Resumen de Resultados

- **Métrica**: rmse
- **Modelo ganador**: mlp

2. Justificación Estadística

- Prueba de Friedman: Significativa
- p-valor: 0.027946

3. Interpretación Científica

El modelo mlp muestra un rendimiento superior estadísticamente significativo.

4. Limitaciones

- El análisis se basa en los resultados de Cross Validation.
- La generalización depende de la representatividad del dataset.

5. Recomendaciones

- Utilizar el modelo mlp para predicciones.
- Considerar validar en datos externos.